COMP6704 个人作业
选题方案说明报告

非凸 CNN 训练中 SGD、Momentum 与 Adam 的比较
收敛效率、稳定性与学习率敏感性

英文题目：Comparing SGD, Momentum, and Adam for Nonconvex CNN Training: Convergence, Stability, and Learning-Rate Sensitivity

课程：COMP6704 — Advanced Topics in Optimization | 学期：Fall 2026

姓名：_____ 学号：_____ 方案日期：2026 年 11 月 5 日

文件性质：选题与实施计划，尚未开展正式实验。文中的数据规模、算法与预算为拟采用方案；没有报告任何已取得的准确率、算法排名或训练耗时。

1 选题概述与研究价值

本项目拟研究固定小型卷积神经网络（CNN）训练中的无约束非凸优化问题。在统一模型、数据和训练预算下，比较普通随机梯度下降（SGD）、带动量的 SGD（Momentum）和 Adam，分析三类更新机制在收敛速度、学习率敏感性、随机种子稳定性及预测表现上的差异。

小组项目已选择 Convex Optimization；本个人项目选择 Unconstrained Optimization，核心对象是对网络参数非凸的经验风险最小化。个人研究的问题定义、实现、实验和分析拟独立完成，选题说明通过数学性质和研究问题体现区别。作业原文未细化“不同选题”的判定边界，本方案不将方向名称本身视为自动符合要求的保证。[8]

1.1 研究问题

编号	拟回答的问题
RQ1	经过等额学习率搜索后，三种方法的损失下降速度与实际运行效率有何差异？
RQ2	各方法对初始学习率及随机初始化的敏感程度如何？
RQ3	训练损失、验证 / 测试表现与运行时间，是否给出一致的评价？

项目的主要贡献定位为受控比较和机制分析。三种经典算法比较本身不构成新算法；研究深度将由清晰建模、更新机制分析、公平实验、敏感性分析和可复现证据支撑。

1.2 范围与完成标准

核心范围固定为一个真实数据集 CIFAR-10、一个小型 CNN、三个优化器、等预算调参和三个新的最终随机种子。首先完成核心实验与报告；学习率调度消融属于可选扩展，不进入最低交付要求。

2 文献基础与正式问题定义

文献阅读围绕三条线索展开：动量与初始化、Adam 的自适应更新、优化器比较中的调参公平性。Sutskever 等讨论了动量与初始化对深度网络训练的影响；Kingma 与 Ba 提出基于梯度一阶、二阶矩估计的 Adam。[1－2]

Sivaprasad 等将超参数搜索成本纳入优化器评价，说明比较不能仅依赖一组随意选定的默认参数。[3] 近期 Wen 等在大模型预训练中进一步讨论了不等额调参和评价时点造成的偏差。[4] 本项目借鉴其比较原则，不将大模型实验的算法排名外推到 CIFAR-10。

2.1 目标函数与问题性质

$$\min_{\theta \in \mathbb{R}^p} F(\theta) = \frac{1}{N} \sum_{i=1}^{N} \ell_i(\theta), \qquad \ell_i(\theta) = -\log \frac{\exp(z_{i,y_i})}{\sum_{c=1}^{10} \exp(z_{i,c})}$$

其中，N 为训练样本数量， θ 为全部可训练参数，p 为参数维数；z_i=f_θ(x_i) 为样本 i 的十类输出 logits，y_i 为真实类别， _i 为交叉熵。实现中模型直接输出 logits，交叉熵损失内部完成相应计算。

参数空间为 R^p，不设置显式等式或不等式约束；卷积、激活和多层参数的组合使目标对 θ 非凸。主实验不加入权重衰减或显式 L2 正则项，使三种方法求解同一目标。

2.2 数据与预处理

CIFAR-10 包含 60,000 张 32×32 彩色图片、10 个类别，官方训练集 50,000 张、测试集 10,000 张。[5] 拟按类别分层，从官方训练集中固定划出 45,000 张用于训练、5,000 张用于验证；测试集保持独立。

划分随机种子拟设为 20261105，并保存样本索引。按通道标准化的统计量仅从 45,000 张训练图片计算，再用于验证和测试。主实验采用确定性预处理，不引入随机数据增强，以减少混杂因素。

2.3 固定网络结构

模块	配置与输出形状
卷积块 1	Conv 3→32，3×3、padding=1；ReLU；2×2 MaxPool → 32×16×16
卷积块 2	Conv 32→64，同上 → 64×8×8
卷积块 3	Conv 64→128，同上 → 128×4×4
分类头	Flatten 2048 → Linear 128 → ReLU → Linear 10（logits）

所有卷积与线性层均保留偏置，共 356,810 个可训练参数，约 0.36M。主实验不使用预训练、BatchNorm 或 Dropout；模型与初始化规则在正式实验前锁定。

3 拟比较的优化算法与理论分析

令 B_t 为第 t 步的小批量样本，三种方法使用相同定义的随机梯度：

$$g_t = \frac{1}{|B_t|} \sum_{i \in B_t} \nabla_\theta \ell_i(\theta_t)$$

3.1 普通 SGD

$$\theta_{t+1} = \theta_t - \eta g_t$$

SGD 作为基础方法，直接沿小批量梯度的负方向更新。拟分析学习率与损失下降速度、波动及发散现象的关系。主实验使用常数学习率。

3.2 Momentum SGD

$$b_t = \mu b_{t-1} + g_t, \qquad \theta_{t+1} = \theta_t - \eta b_t, \quad b_{-1} = 0$$

固定 μ=0.9、初始动量为零，采用普通动量形式，不使用 Nesterov。拟分析梯度累积能否减轻震荡、加快某些方向的下降，以及动量与学习率之间的相互影响。[1]

3.3 Adam

$$m_t = \beta_1 m_{t-1} + (1-\beta_1) g_t, \qquad v_t = \beta_2 v_{t-1} + (1-\beta_2) g_t^2$$

$$\widehat{m}_t = \frac{m_t}{1-\beta_1^{t+1}}, \quad \widehat{v}_t = \frac{v_t}{1-\beta_2^{t+1}}, \quad \theta_{t+1} = \theta_t - \eta \frac{\widehat{m}_t}{\sqrt{\widehat{v}_t} + \varepsilon}$$

Adam 的状态从零初始化，梯度平方、平方根和除法均按元素执行；t 从 0 开始。固定 β1=0.9、β2=0.999、ε=10^-8，仅搜索初始学习率。拟分析自适应缩放的早期效率、敏感性与后期表现。[2]

3.4 复杂度与理论边界

方法	参数更新开销	额外优化器状态
SGD	每步 O(p)	无动量或矩估计状态
Momentum	每步 O(p)	约 p 个标量
Adam	每步 O(p)	约 2p 个标量，另有少量计数状态

上述开销不包含网络前向、反向和数据加载；实际耗时由这些环节共同决定。最终报告拟推导更新公式，解释状态和步长机制，并结合实验分析，而非仅列准确率。

理论边界：CNN 目标非凸，ReLU 又不满足通常的全局光滑假设。理想光滑非凸情形的驻点收敛理论仅作为背景，并非本实验的直接保证。真实全局最优值未知，因此记录训练损失，不将其称为最优性差距，也不预设 Adam 必胜。

4 实验协议与计算预算

4.1 先试跑，再锁定正式协议

先检查独立环境中的 PyTorch/CUDA 可用性，确认前向、反向和三种更新均能运行。随后用短试跑检查损失趋势、显存、每轮耗时和学习率范围。试跑仅服务于可运行性和预算设计，不用于最终种子统计；其运行成本另计。

正式训练统一采用 20 或 30 epochs，由试跑后确定。学习率候选、训练轮数、batch size、选参规则及种子在正式实验前锁定；调参与最终比较使用相同轮数，避免仅按很短的早期训练选择学习率。

4.2 初始配置与学习率搜索

优化器	初始学习率候选	固定设置
SGD	0.01、0.03、0.1	momentum=0
Momentum	0.01、0.03、0.1	momentum=0.9
Adam	0.0003、0.001、0.003	$\beta_1=0.9$，$\beta_2=0.999$，$\varepsilon=10^{-8}$

共同设置：batch size 初始为 128、float32、常数学习率、weight_decay=0、不裁剪梯度。候选范围是起点；试跑后统一冻结。如范围不足，须在正式阶段之前调整并记录依据。相同候选数量不等于已经找到各算法的全局最佳配置。

4.3 正式运行次数与选参规则

阶段	运行设计	次数
学习率选择	3 个优化器 × 3 个学习率 × 调参种子 100	9
最终比较	3 个优化器 × 新种子 {11,22,33}	9
合计	不包含环境检查、smoke test 和 pilot	18

调参以第 E 个 epoch 的验证集平均交叉熵最低为选参规则；平局按预先规定的学习率顺序处理。最终实验固定使用第 E 个 epoch 的参数，不按测试表现或最好种子挑选结果。配置和评价规则锁定后，才对测试集统一评价。

令统一轮数为 E，正式训练总量为 18E：E=20 时为 360 个数据集轮次，E=30 时为 540 个。每轮约 352 次参数更新（45,000 个样本、batch=128、不丢弃最后一批）。验证与训练损失评估还会增加前向计算成本。

4.4 配对比较与预算解释

同一最终种子在三种算法之间共享初始权重和小批量顺序，各算法从同一状态独立开始，形成配对比较。三个最终种子是新的种子，不参与调参；并非使用九个不同种子。固定 epochs 衡量相同数据遍历预算下的表现；墙钟时间用于补充实际效率，两者分别报告。

5 评价、分析与可复现性

5.1 拟记录的结果

结果或图表	记录与解释方式
训练损失—epoch / step	每轮结束后用固定模型、eval 模式及相同训练集计算平均损失；与在线批次损失区分。
训练损失—时间	时间轴对应相同的训练与评估流程，观察降低相同损失所需的实际代价。
验证损失 / 准确率	观察优化进展与泛化表现是否同步，说明可能的过拟合或欠拟合。
最终测试表现	三种算法分别报告三个种子的交叉熵、准确率均值与样本标准差，保留全部单次结果。
学习率敏感性	复用调参日志绘制候选学习率与验证表现；明确这部分仅使用一个调参种子。
稳定性与失败案例	记录训练曲线震荡、非有限损失、未达到目标或不同种子表现差异，不静默删去失败运行。

若使用“到达某个损失阈值的时间”，阈值须在正式实验前固定，未达到时如实标记。三个种子提供的是初步稳定性证据；不据此作强统计显著性或普遍最优结论。所有结论限定在指定模型、数据、有限搜索范围和训练预算之内。

5.2 计时与运行控制

GPU 实验顺序执行，避免并发训练互相影响。主要计时区间从第一个训练批次之前开始，到最终训练及规定评估结束为止；不计下载、绘图和 checkpoint 写盘。验证及训练损失评估频率保持相同，并在报告说明计时范围。

使用高精度墙钟计时，并在 GPU 计时边界同步 CUDA；另外记录每轮时间和峰值显存。笔记本接电、使用一致电源设置，记录是否发生明显降频或其他任务干扰。准确耗时待试跑后测定，不由显卡型号直接推算。

5.3 实现与复现交付

训练采用 PyTorch 自动微分，优化器实现按更新公式说明并与官方接口一致；入门流程参考官方 CIFAR-10 教程。[6] 可在极小张量上核对一步更新，确认参数、动量初始化和 Adam 偏差修正的对应关系。

拟保存：数据划分索引、标准化统计量、模型定义、所有超参数、种子、软硬件版本、原始 CSV 日志、最终结果和生成图的命令。README 写明环境建立、试跑、正式实验及汇总方法；最终报告提供可访问的代码链接。

复现边界：固定 Python / NumPy / PyTorch 及数据加载器随机源；尽量统一确定性设置并记录配置。同一环境应能复现主要结论，但不承诺不同 GPU、驱动或软件版本下逐位相同。

6 设备条件、实施进度与风险控制

条件	已知情况与实施安排
计算设备	i7-13700HX（16 核、24 线程）；RTX 4070 Laptop、约 8 GB 显存；整机约 16 GB 内存。
运行环境	已有 Windows Python / Anaconda；常用环境检查未发现 PyTorch。优先使用独立 Windows 环境及兼容的 CUDA 版 PyTorch。
核实边界	驱动可识别显卡；PyTorch/CUDA 尚未实际跑通。当前 WSL 内存配额约 7.6 GiB，不作为整机内存解释。
使用条件	每日主动投入约 1 – 2 小时；Python 基础已有，PyTorch 经验较少。预计人工投入约 30 – 40 小时，自动训练时间另计。

6.1 日程与完成标志

日期（2026）	工作与完成标志
11/5 – 11/8	完成基础阅读、选题说明、独立环境和试跑；取得显存与耗时记录，锁定实验协议。
11/9 – 11/12	完成固定模型、数据划分、统一日志与三个算法；检查小规模训练和一步更新。
11/13 – 11/17	执行 9 次调参和 9 次最终运行；保留原始日志，完成配置锁定后的测试评价。
11/18 – 11/21	汇总曲线与统计，解释学习率敏感性、训练与泛化差异，固定主要图表和结论。
11/22 – 11/26	完成最终报告、引用、代码及 README；为写作和复现合计预留至少 10 – 12 小时。
11/27 – 11/28	从文档运行命令复查主要流程，检查 PDF 和代码链接，提前上传 Canvas。
11/29	最终缓冲；23:59 前完成提交，以 Canvas 显示的时区和时间为准。

6.2 关键风险与应对

环境配置：优先使用兼容的官方预编译包和独立环境，避免影响已有项目。初次数据加载从 num_workers=0 开始，稳定后再评估是否增加。GPU 尚未可用时，可先在 CPU 上用同一数据小子集调通流程，及早决定是否需要缩小正式规模。

运行预算：根据试跑耗时决定统一采用 20 或 30 epochs；保留三种算法和三个最终种子。若进度紧张，先取消所有扩展，不在看到某一算法结果后单独增加其训练预算。

解释与范围：不预设 Adam 获胜，不追求预定准确率；结果不理想时分析学习率范围、预算、网络容量和波动。单数据集、单模型及少量种子的外推能力有限，应在最终报告明确。

7 预期交付与课程要求对应

本阶段交付为选题方案说明报告。项目完成后拟交付：不超过 10 页的最终课程报告、可访问的实验代码与 README、锁定配置、数据划分、原始日志、结果汇总及绘图脚本。姓名和学号由学生在正式提交前补充。

课程评分项	方案中的对应工作
文献综述 20%	基础算法、调参公平性与近期发展，解释方法和问题的联系。
问题建模 20%	经验风险、交叉熵、参数空间、非凸性质及数据划分。
算法 20%	SGD / Momentum / Adam 更新公式、机制、复杂度及一致实现。
实验分析 30%	等预算调参、独立最终种子、收敛与计时、敏感性及失败案例。
可复现性 10%	运行说明、固定配置、版本和种子、原始日志与图表生成。

最终报告建议分配：摘要与引言 1 页、相关工作 1 页、问题与方法 2.5 页、实验与分析 4 页、结论 0.5 页、参考文献 1 页，总计 10 页。作业未明确参考文献可排除于页数限制，因此按整份 PDF 不超过 10 页安排。[8]

参考文献与资料

[1] Sutskever, I., Martens, J., Dahl, G., & Hinton, G. (2013). On the importance of initialization and momentum in deep learning. ICML, 28(3), 1139–1147. [原文链接]

[2] Kingma, D. P., & Ba, J. (2015). Adam: A Method for Stochastic Optimization. ICLR; arXiv:1412.6980. [原文链接]

[3] Sivaprasad, P. T., Mai, F., Vogels, T., Jaggi, M., & Fleuret, F. (2020). Optimizer Benchmarking Needs to Account for Hyperparameter Tuning. ICML, 119, 9036–9045. [原文链接]

[4] Wen, K., Hall, D., Ma, T., & Liang, P. (2026). Fantastic Pretraining Optimizers and Where to Find Them. ICLR. [原文链接]

[5] Krizhevsky, A. CIFAR-10 and CIFAR-100 datasets. 数据集官方说明，访问日期：2026-11-05。 [原文链接]

[6] PyTorch. Training a Classifier. 官方 CIFAR-10 入门教程，访问日期：2026-11-05。 [原文链接]

[7] PyTorch. Get Started Locally. 环境安装参考，访问日期：2026-11-05。 [原文链接]

[8] COMP6704: Advanced Topics in Optimization. Individual Assignment, PolyU Fall 2026. 用户提供的课程作业要求，第 1–3 页。

实施起点：完成一页项目摘要、可调用 GPU 的统一训练基线及试跑测时记录；随后冻结正式实验协议。